




Instituto Tecnológico  
de Buenos Aires

11/OCTUBRE

**K-NEAREST**

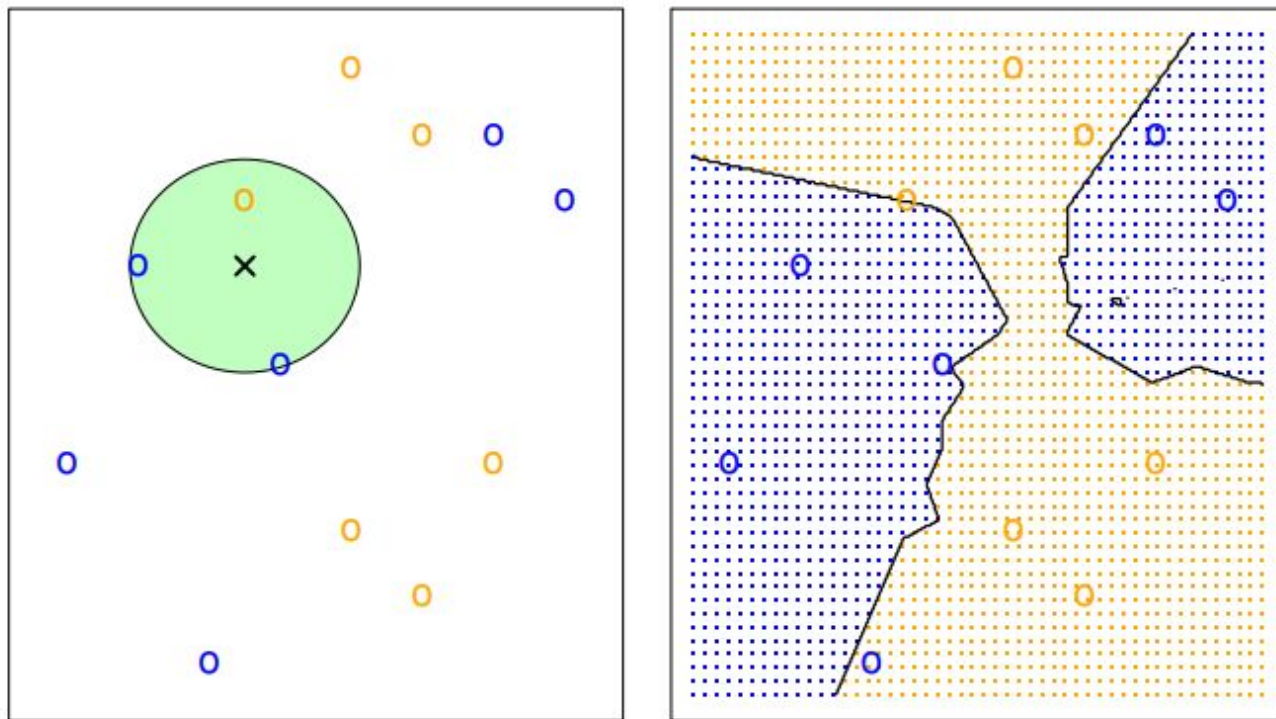
**NEIGHBOURS**

—



¿Cómo predecimos la clase de  $\mathbf{x}$ ?

## K-nearest Neighbors (KNN)



**K=3**


$$\Pr(Y = j|X = x_0) = \frac{1}{K} \sum_{i \in \mathcal{N}_0} I(y_i = j)$$

**Para clasificar  $x_0$ :**


1. Buscar  $K$  puntos en train más cercanos a  $x_0$  [**vecindario  $\mathcal{N}_0$** ]
2. Calcular la distribución de clases en  $\mathcal{N}_0$  [ **$\Pr(Y)$** ]
3. Asignar a la clase de mayor probabilidad (solemos usar  $K$  impar)

# KNN

KNN: K=1



KNN: K=100



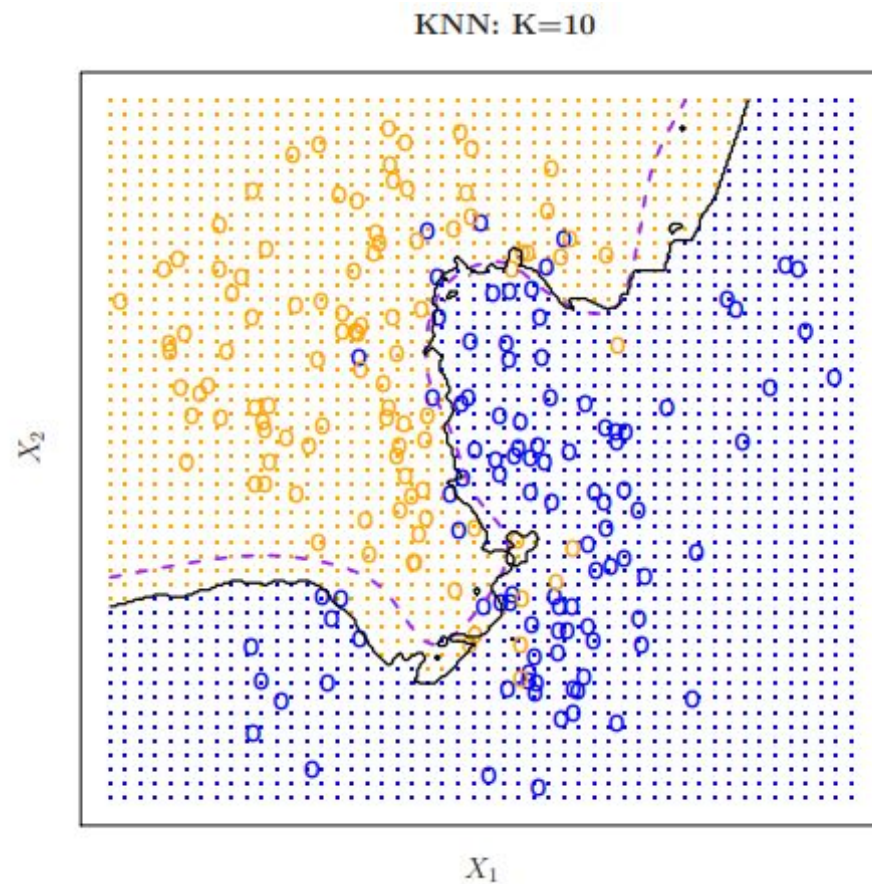
- Componente sistemático del DGP (“verdadera” frontera de clasificación)
- Observaciones de entrenamiento de cada clase

*Tasa de error de clasificación*

$$\frac{1}{n} \sum_{i=1}^n I(y_i \neq \hat{y}_i)$$

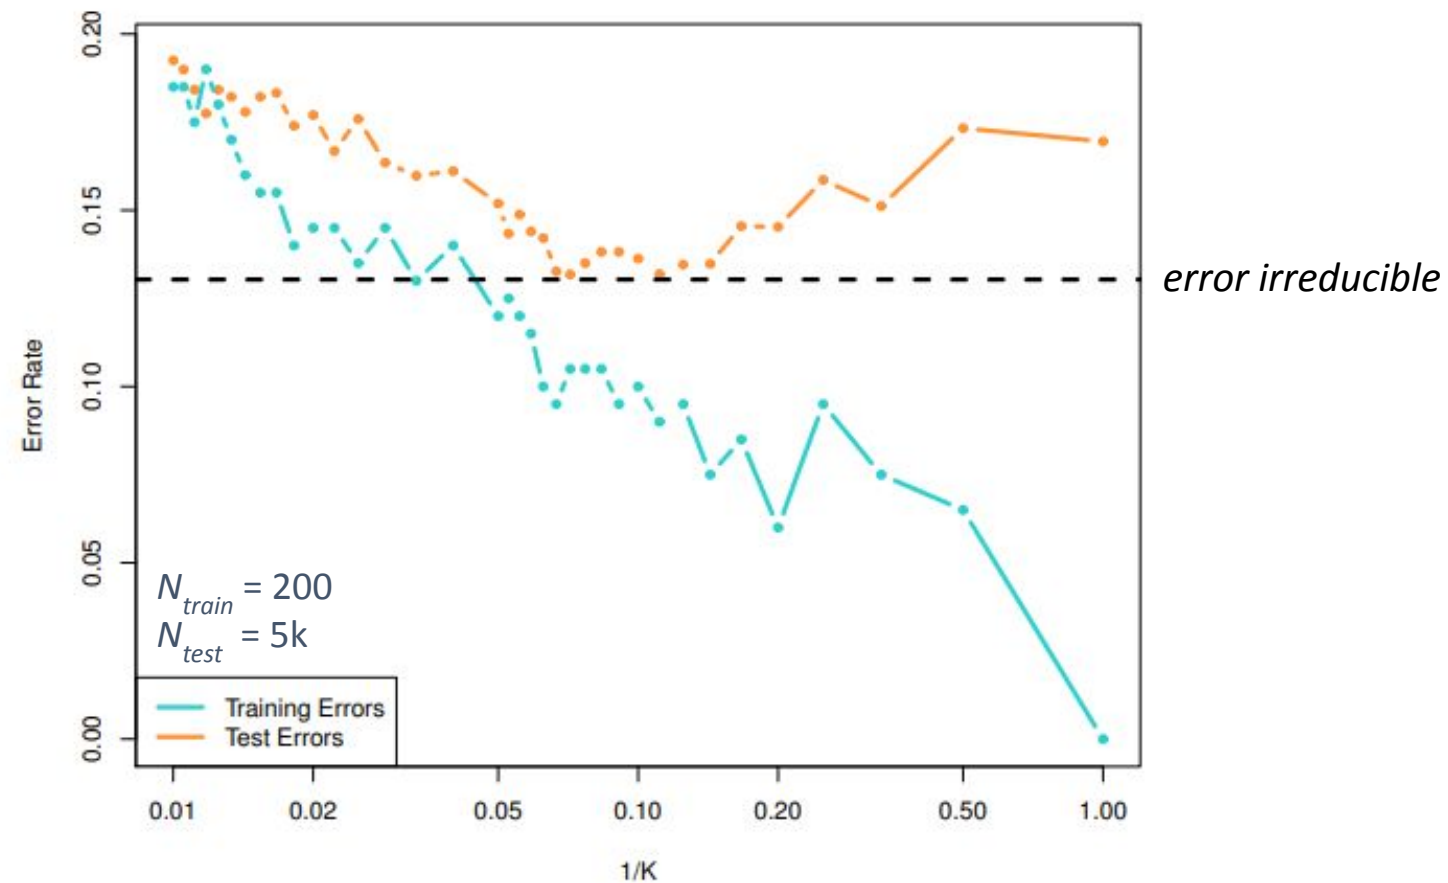
¿Cómo es el error en cada  $K$ ?

## KNN







## KNN



## Tradeoff sesgo-varianza



# Tradeoff sesgo-varianza



**+k -flexibilidad**  
→ **-sesgo +varianza**


**-k -flexibilidad**  
→ **+sesgo -varianza**

Para  $K=1$ , la predicción depende de una sola observación!  
Cuando  $K$  crece, depende del promedio de muchas




# KNN regression

$K=1$



$K=9$




$$\hat{f}(x_0) = \frac{1}{K} \sum_{x_i \in \mathcal{N}_0} y_i$$

Para predecir la respuesta de  $x_0$ :


1. Buscar  $K$  puntos en train más cercanos a  $x_0$  [**vecindario  $\mathcal{N}_0$** ]
2. Calcular el promedio de  $Y$  en  $\mathcal{N}_0$  [ **$\hat{f}(Y)$** ]

# KNN regression



$K=1$



$K=9$





# KNN regression





KNN

MCO


# KNN regression



# KNN regression



# KNN vs Modelos lineales




En DGP **no lineales**, KNN tiene mejor rendimiento  
A diferencia de MCO, **es un método local y no paramétrico**  
[no asume una forma específica de  $f(X)$ ]

¿Esto quiere decir que MCO no sirve en este escenario?





# KNN vs Modelos lineales



¿Esto quiere decir que MCO no sirve en este escenario?



**NO!** Podríamos transformar  $x$  para mejorar el ajuste de MCO :)

## KNN vs Modelos lineales



¿Cuántos *valores* necesitamos en memoria para hacer la predicción de una observación nueva con MCO?  
¿Y con KNN?

## KNN vs Modelos lineales



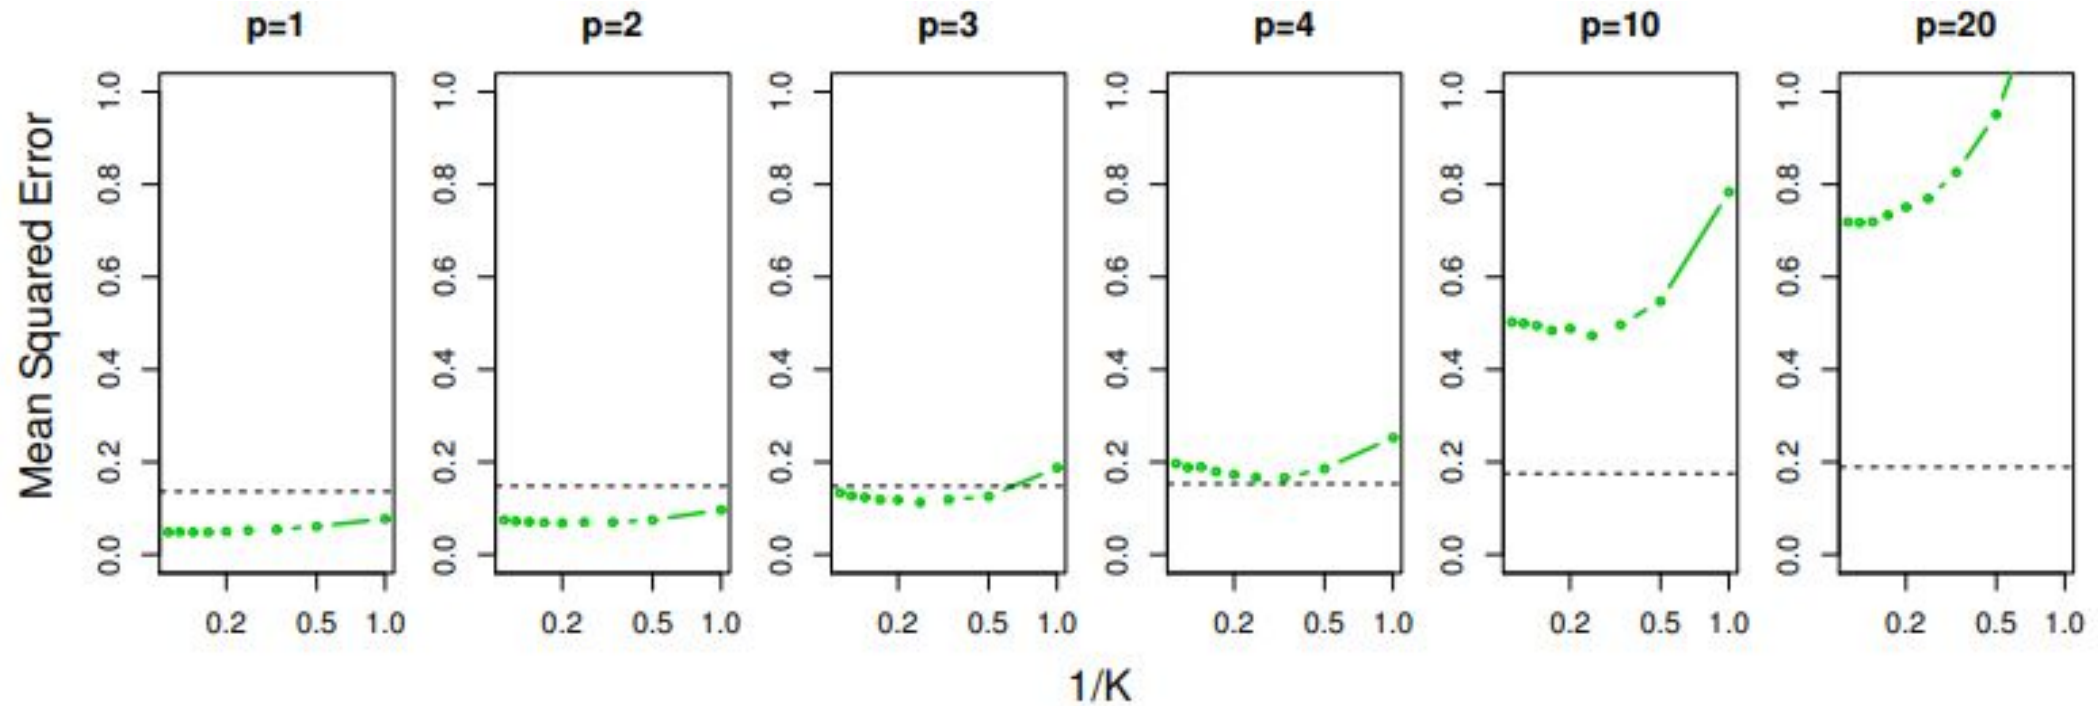
¿Cuántos *valores* necesitamos en memoria para hacer la predicción de una observación nueva con MCO?  $\beta_0$  y  $\beta_1$

¿Y con KNN? La matriz de observaciones  $n \times p$

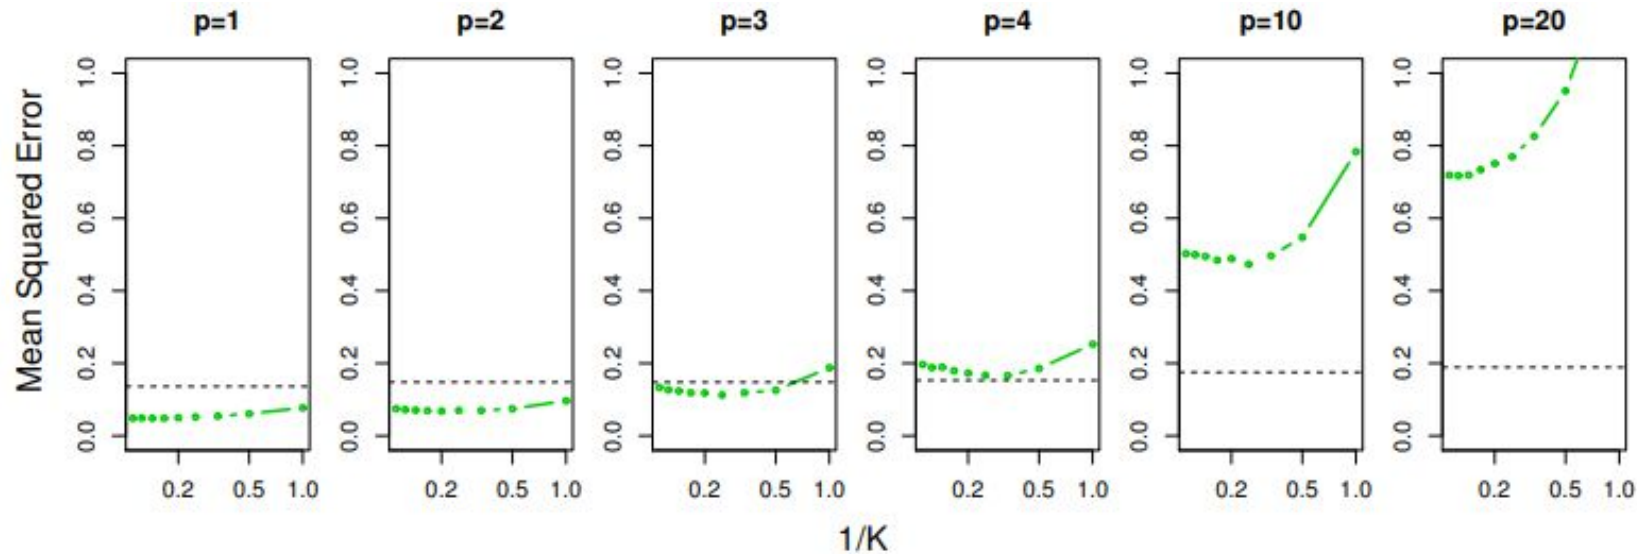
→ KNN es costoso en términos de memoria y cómputo (necesitamos calcular la matriz de distancias y encontrar los mínimos)

# KNN vs Modelos lineales

¿Qué pasa si agregamos covariables irrelevantes al escenario anterior?  
 $j=2,\dots,20$



## KNN y *La Maldición de la Dimensionalidad*



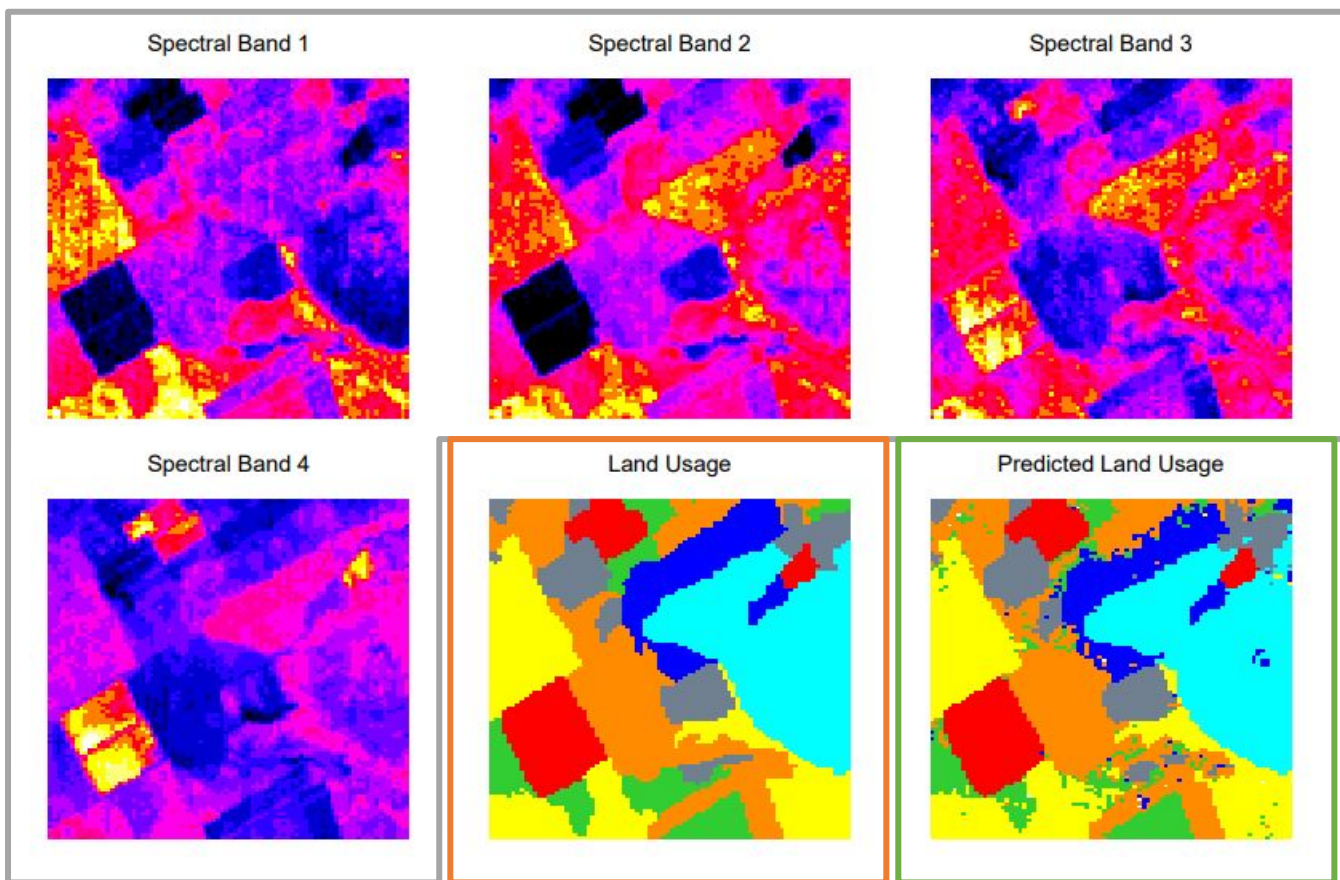
¡Las distancias se deterioran mucho en dimensión alta! (alto  $p/N$ )  
→ Para seguir encontrando individuos parecidos a medida que aumentamos  $p$ , necesitamos aumentar  $N$  exponencialmente

# Aplicación en imágenes satelitales

¿Cuál es el uso de la tierra  $Y$  de cada píxel  $x$ ?

(Michie et al, 1994)

82 x 100



$k=5$

$y \in \{\text{red soil, cotton, gray soil, mixture, ...}\}$

$X$

*featurización*

N	N	N
N	X	N
N	N	N

1 pixel + 8 neighbors

$$\phi(X) \in \mathbb{R}^{36}$$

feature map

$$\hat{y} = \hat{f}(\phi(X))$$

**KNN**



## Lecturas recomendadas

- [An Introduction to Statistical Learning](#)  
2.2.3 + 3.5
- [The Elements of Statistical Learning](#)  
2.3 + 2.9 + 13.3 + 14.3.2 + 14.3.3
- [Probabilistic Machine Learning: An Introduction](#)  
16.1

